AI 加速仿真与全场应力校准技术方案

背景

在航空航天及高端机械装备制造中，结构件在实际服役过程中，往往需要承受复杂且剧烈的**随机振动载荷**。为了验证这些结构件（TC4钛合金）在不同几何构型、不同配重（模拟质量变化）下的可靠性，通常需要进行**基于有限元分析（FEA）结构动力学响应分析，这一过程一般包括：结构参数化 → 有限元离散 → 振动激励 → 频域响应 → 统计量输出**。这一物理过程的精确预测，是结构强度校核与轻量化设计的核心前提。

实物图

几何结构参数建模

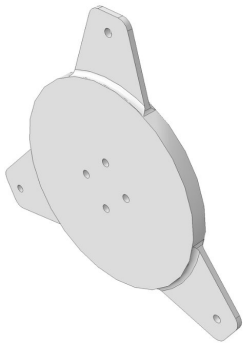

单零件简化图

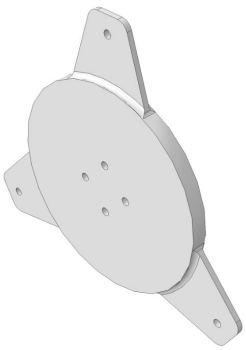

零件图

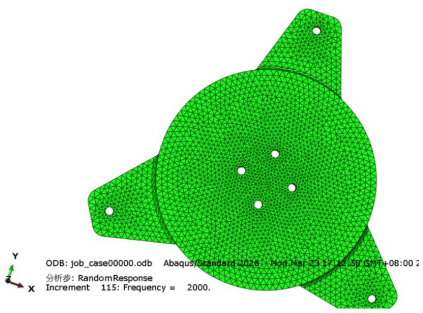

零件网格图

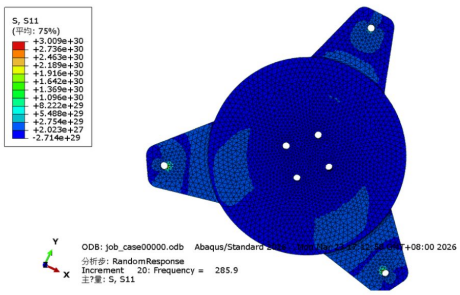

仿真结果图

传统FEA仿真流程局限性

- **计算成本高**：传统 FEA 软件底层依赖复杂的矩阵求解，单次计算时间长，无法满足海量设计参数的实时评估与脚本化自动寻优。参数变化需重复仿真，难以支撑快速迭代 。
- **跨结构表征难**：传统仿真高度依赖网格。当结构件的几何参数发生变化（如圆盘半径从130mm缩减至90mm）时，须重新划分网格。这导致**输出的全场数据维度和空间节点信息发生剧烈改变**。这种“非结构化”的数据变化，使得传统方法极难提取统一的几何特征，也无法实现跨结构的物理场统一表征。
- **Sim2Real Gap**：材料、阻尼、加工误差与边界误差导致仿真与实测偏差

> 原始需求：HT6Y-需求细节

问题定义

在学术界和计算力学领域，定义为以下两类经典问题：

问题一：高维偏微分方程的AI代理建模 (Surrogate Modeling for PDEs)

- **问题解释：** 传统的 FEA 是在求解复杂的固体力学偏微分方程。**AI 代理模型**的本质，是利用深度学习在高维空间中拟合一个极其复杂的非线性映射函数 $Y = f(X)$。其中输入 X 包含几何域、边界条件和物理参数，输出 Y是全场的响应（如应力场）。
- **解决方案**：引入**深度学习，跳过传统繁琐的网格化与PDE求解过程**，建立“几何设计数据 $\rightarrow$ 深度学习模型 $\rightarrow$ 全场力学响应数据”的端到端预测模型。实现**秒级**的全场应力与加速度预测，更通过**融合真实测试数据**，打通虚实闭环，完成全场应力的高精度校准。

问题二：不适定逆向反演与数据同化 (Ill-posed Inverse Problem & Data Assimilation)

- **定义解释：** 已知系统输出（少数传感器的真实读数），要求反推系统的输入（真实的物理载荷或材料属性），这被称为逆问题（Inverse Problem）。由于未知数（全场节点）远大于已知数（少数测点），这在数学上是一个典型的**不适定问题（Ill-posed）**，即存在无数种解都能满足这几个点的数值。必须引入强大的“物理先验知识”进行正则化，才能求出唯一且真实的物理参数。

> 1. **“盲人摸象”式的真实测试：** 真实零件在台架测试中，受限于传感器体积和贴片成本，通常只能获取极少数点（如 5-10 个应变片）的局部响应，无法观测全场应力分布。
> 2. **仿真模型失真（缺乏校准）：** 由于加工误差、材料属性波动或装配预紧力的差异，初始的理想仿真结果往往与真实传感器的测量值不符，传统试错法校准模型成本极高。

技术方案

阶段0：自动化数据流水线与图数据集构建

几何参数和载荷参数化需求转化为高质量的 Graph 数据集。

1. **参数空间采样 (DOE)**

- **输入:** 8 个几何与质量参数（耳片厚度、半径、附加质量等）。

- **处理:** 使用 **拉丁超立方抽样 (LHS)** 生成 3000-5000 组参数矩阵。针对 `Add_mass` (0-10kg) 和 `earpiece_thickness` 进行局部加密采样，因为质量与刚度对抗震响应的频移影响最大。
- **输出:** `doe_matrix.csv` (N行 8列)。

2. **Abaqus 自动化无界面仿真 (Headless Simulation)**

- **输入:** `doe_matrix.csv` 以及给定的两组 PSD 随机振动载荷谱。
- **处理:** * 编写 Abaqus Python 脚本，循环读取 DOE 参数。
  - **几何建模:** 驱动 CAD 内核自动更新草图、拉伸圆盘与耳片、倒角（联动约束上下底边连续）。
  - **物理属性:** 赋予 TC4 材料 $E = 109000\ \mathrm{MPa}, \rho = 4.44 \times 10^{-9}\ \mathrm{t/mm^3}$ 。将中心附加质量 `Add_mass` 转化为 Point Mass，并通过 Coupling 约束与内孔面耦合。
  - **网格划分:** 采用十节点二次四面体单元 (C3D10)，在倒角处 (`earpiece_BottomFilletRadius`) 进行局部网格细化 (Mesh Refinement)。
  - **分析步:** * Step 1: `*FREQUENCY` （Lanczos 法提取前 10 阶固有频率）。
    - Step 2: `*RANDOM RESPONSE` （施加基座 Z 向加速度激励，输入 PSD 曲线）。
- **输出:** 批量生成的 `.odb` 结果文件。

3. **Graph 拓扑提取与特征封装**

- **输入:** 批量的 `.odb` 文件。
- **处理:** 放弃低效的 Abaqus 原生遍历，编写 Python 脚本调用 `abaqus python -c` 结合 C++ ODB API，快速导出节点坐标、单元连接关系以及 RTA/RMises 结果场，存为 `.vtu` 格式。最后用 `PyTorch Geometric (PyG)` 封装。
- 图的定义
- $G = (V, E, U)$
  - **节点特征 X_v (Node):** $[x, y, z, \mathrm{BC_mask}]$ （坐标与边界条件掩码，尺寸 $N \times 4$ ）。
  - **边特征 X_e (Edge):** $[dx, dy, dz, \|d\|_2]$ （基于网格连通性计算的相对距离，尺寸 $E \times 4$ ）。
  - **全局特征 U (Global):** $[P_1, P_2, ..., P_8, F_1, F_2, F_3, \mathrm{PSD_feature}]$ （8个几何质量参数 + 前3阶固有频率 + PSD载荷特征）。
- **目标标签 Y_v (Target):** $[\mathrm{RTA}, \mathrm{RMises}]$ （每个节点的稳态均方根响应，加速度、应力，尺寸 $N \times 2$ ）。

阶段1：基于模态先验的 GNN 代理模型

将几何参数、物理载荷映射到全场响应，实现毫秒级预测。

4. **双支路网络架构设计**

- **先验分支 (MLP):**

- **输入:** 8 个几何与质量参数。
- **输出:** 预测该结构的前 3 阶固有频率 (f_1, f_2, f_3)。
- *作用:* 提前为图神经网络“注入”系统的动态刚度特征，大幅降低 GNN 学习频谱映射的难度。

- **主干网络 (MeshGraphNet with Global Context):**
  - **Encoder:** 将节点坐标、边特征通过全连接层映射到 128 维的隐空间。同时将“先验分支预测的频率 + 8个参数 + PSD特征”拼接到每个节点的隐特征中。
  - **Processor:** 执行 10 层 Message Passing (消息传递)，允许特征在网格边上流动，模拟应力分布。
  - **Decoder:** 将更新后的节点隐特征降维。
  - **输出:** 预测全场节点上的 RTA 和 RMises。

> 这种“既是先验分支的输出，又是主干网络的输入”的设计，核心是为了**解耦物理过程，降低深度学习拟合的难度**。从“物理本质”和“AI 模型推理流程”两个维度来彻底理清这个逻辑。
>
> 1. **物理本质：为什么要强行显式化“固有频率”？**
>
> 在随机振动（模态叠加法）中，系统响应的计算逻辑是一条极其陡峭的非线性路径：
>
> **几何/质量参数 ($P_1 ... P_8$) -> 刚度/质量矩阵 ->求解特征值方程 -> 固有频率 ($F_1 ... F_3$) -> 结合 PSD 谱计算共振放大 -> 全场 RMS 响应。**
>
> 如果我们只用一个纯粹的 GNN，直接让它建立 $[P_1 ... P_8] \to [\mathrm{RTA}, \mathrm{RMises}]$ 的映射，这意味着 **GNN 必须在黑盒内部隐式地学会“求解高维特征值方程”**。
>
> 大量 AI4S 的研究表明，**GNN 极度擅长局部的空间物理量平滑传递**，但非常**不擅长**隐式推导全局的频谱特性。如果让 GNN 硬学，不仅极难收敛，而且一旦参数变化导致固有频率刚好跨越了 PSD 谱的某个能量台阶，GNN 的预测就会发生灾难性的偏离。
>
> 因此，我们引入 MLP 作为一个“物理先验提取器”，强行把隐式的特征值求解过程显式化。
>
> 2. **信息流转逻辑：训练期与推理期的身份转换**
>
> 固有频率 (F_1, F_2, F_3) 在不同阶段扮演着不同的角色。
>
> **在准备阶段（Abaqus 数据集制作）：**
>
> 你的 Abaqus 脚本不仅会输出全场的 RMS 响应，还会在 `*FREQUENCY` 分析步中提取出真实的固有频率 F_{true} 。此时， F_{true} 是数据集里的真实标签（Ground Truth）。
>
> **在训练阶段 (Training)：**
>
> 整个网络同时执行两个任务：
>
> 1. **MLP 分支：** 输入几何参数 $P_1 ... P_8$ ，输出预测的频率 $\hat{F}_1, \hat{F}_2, \hat{F}_3$ 。通过与 F_{true} 对比，计算 MSE 损失，专门训练 MLP。
> 2. **GNN 主干：** 它的全局特征 U 会接收 MLP 刚刚预测出来的 $\hat{F}_1, \hat{F}_2, \hat{F}_3$ （或者在初期训练时直接输入 F_{true} 帮助模型稳定，这叫 Teacher Forcing），结合 $P_1 ... P_8$ 和 PSD 谱，去预测全场响

> **在部署/推理阶段 (Inference/Deployment)：**
>
> 当模型交付给甲方，或者用于逆向反演时，**Abaqus 已经被彻底踢出局了**。
>
> 此时输入一个全新的几何组合（比如耳片厚度变为 5.5mm），我们**没有**真实的固有频率。
>
> 信息流变成这样：
>
> 1. 用户输入 $P_1 ... P_8$ 。
> 2. **MLP 瞬间响应，输出预测的前 3 阶频率** $\hat{F}_1, \hat{F}_2, \hat{F}_3$ 。
> 3. 这 3 个预测出的频率，连同 $P_1 ... P_8$ ，**作为输入**注入到 GNN 的全局特征 U 中。
> 4. GNN 输出全场 RMS 响应。
>
> **总结**
>
> MLP 预测频率并喂给 GNN，本质上是一种 **Physics-Informed（物理信息注入）** 的网络架构工程。它把一个几乎不可解的“端到端黑盒”拆成了两步：
>
> - **Step 1 (MLP):** 专职负责将“几何/质量”映射到“频域特征”（容易拟合）。
> - **Step 2 (GNN):** 专职负责将“频域特征+载荷”分配到“全场空间节点”（发挥 GNN 局部消息传递的特长）。

5. **损失函数设计 (Loss Function)**

为了解决倒角处应力集中的预测误差，引入**误差加权机制**：

$$L_{forward} = \frac{1}{N} \sum_{i=1}^{N} \left[\alpha_i (RTA^i_{pred} - RTA^i_{true})^2 + \beta_i (RMises^i_{pred} - RMises^i_{true})^2 \right]$$

说明: 权重 β_i 根据真实的 $RMises_{true}$ 动态分配，高应力区域赋予更高的惩罚权重，强制模型学准最大应力点。

阶段2：真实测试数据同化与参数反演

反演场景设定与搜索空间定义

- **输入:** 振动台上真实结构件在 3-5 个特定测点位置采集到的真实加速度均方根测点数值 RTA_{sensor} 。
- **待反演变量:** 假设由于加工误差，实际的耳片厚度 `earpiece_thickness` 、中心配重 `Add_mass` 以及 TC4 材料的真实弹性模量 E未知。
- **变量约束（核心改变）:** 不再使用 PyTorch 的可求导张量，而是为每个未知参数设定严谨的**物理搜索边界 (Bounds)**。例如，标称厚度 4mm，设置搜索边界为 `[3.5, 4.5]` ，防止算法漫无目的地瞎找。

启发式参数反演

放弃 Adam 优化器，采用全局寻优能力极强的**差分进化算法 (Differential Evolution, DE)** 或贝叶斯优化。算法将整个“物理引擎+AI”视为一个黑盒进行迭代：

- **Step 1 (种群猜测):** 优化算法在设定的公差边界内，生成一批（如 40 组）关于真实物理参数 θ 的猜测组合。
- **Step 2 (物理前处理):** 后台唤醒 Abaqus 脚本，根据这批猜测参数，极速生成对应的网格拓扑并提取前 3 阶固有频率（提供准确的物理先验）。
- **Step 3 (AI 极速推理):** 将网格与频率输入冻结权重的阶段一 GNN 模型，瞬间输出全场 RTA_{pred} 。
- **Step 4 (KD-Tree 空间插值):** 由于每次猜测生成的网格节点都在变动，引入 K 维树（KD-Tree）算法，在全场预测结果中动态检索出距离真实传感器三维坐标 (x, y, z)最近的网格节点，提取预测值。

目标函数与物理正则化

算法不计算梯度，而是纯粹计算当前猜测参数组合的“代价分数 (Cost/Loss)”。目标函数沿用双重考核机制：

$$Cost(\theta) = \sum_{k=1}^{K}(\mathrm{RTA}_{pred}^{k} - \mathrm{RTA}_{sensor}^{k})^2 + \lambda \sum_{j=1}^{M}\left(\frac{\theta_j - \theta_{nominal}^{j}}{Tolerance_j}\right)^2$$

- **说明:** 前一项是模型预测与传感器测点之间的均方残差；后一项是 Tikhonov 物理正则化惩罚。它强制要求：优化算法不仅要让数据对得上，而且反推出来的厚度、质量等物理参数绝不能偏离图纸标称值 $\theta_{nominal}$ 太远（被 $Tolerance$ 公差约束），彻底消除多解等效和物理荒谬解。

输出与交付

- **输出:** 经过 DE 算法优胜劣汰迭代数次（约耗时十几分钟）后，收敛得到的全局代价最低、最符合物理常识的真实零件参数 $\theta_{calibrated}$ 。

> **逆向参数反演的“筛查法则”**
>
> 任何一个参数想要进入最终的“反演寻优池”，必须同时通过以下四道关卡的极度严苛审查：
>
> 1. **高物理不确定性（查误差源头）：** 只校准现实制造、装配或冶炼中容易产生波动（公差大）的变量；坚决冻结机加工精度极高或微观物理上死板的常数。
> 2. **高全局灵敏度（查响应权重）：** 变量的微小改变，必须能引起全局加速度 RMS（传感器读数）的剧烈变化。坚决剔除只影响局部应力集中、对全局共振毫无波澜的微观特征。
> 3. **低共线性/去耦合（打破多解等效）：** 如果两个参数在力学底层公式中起到极其相似的作用（如都能增加弯曲刚度，或都能改变共振频率 $f_n \propto \sqrt{E/\rho}$ ），**绝不能同时反演**。必须执行“冻结一个，校准一个”的铁律，否则优化算法将陷入无限死循环。
> 4. **信息量匹配（防数学病态）：** 待反演的未知数维度，必须**严格小于或等于**台架测试中独立传感器的数量（3-5个）。坚决杜绝“3个方程解10个未知数”的超定荒谬局面。

阶段3：交付形态与验证指标

- **输入:** 阶段一训练好的 GNN 模型权重 `.pt` 文件，阶段二封装好的反演算法代码。

- **输出/交付物:** 一个 Python 命令行工具或轻量级 Web 界面。
  - **正向功能:** 用户输入一组新的几何参数，1 秒内渲染出三维全场 RTA 和 RMises 分布图（基于 PyVista）。
  - **逆向功能:** 用户上传包含传感器数据的 CSV 文件，工具自动推演出当前零件真实的制造误差或材料属性。

以所给的几何结构和输入输出为例构建详细方案

评价指标

为量化技术成果，设定以下四个维度的交付指标：

- **加速比 (Acceleration Ratio)：** AI 代理模型单次推理时间相较于传统 FEA 求解器的加速倍数（目标：> 1000x）。
- **代理模型精度 (Surrogate Accuracy)：** 在测试集上，AI 预测的全场应力/位移与 FEA 真实值之间的平均绝对百分比误差 (MAPE)（目标：全局误差 < 5%）。
- **全场重构误差 (Reconstruction Error)：** 在真实零件上预留“隐藏验证点”，用 3 个已知测点重构全场后，核对隐藏验证点的预测值与实际测量值的误差（目标：误差 < 8%）。
- **反演收敛度 (Calibration Convergence)：** 经过反向校准后，孪生模型在传感器位置的输出值与真实物理测量值的拟合度 R^2 （目标：> 0.95）。

存在的风险与挑战

1. **数据流水线的工程黑洞：** 自动化解析 FEA 软件底层文件（如 `.odb` 或 `.rst`）并构建高质量的 Graph 数据集，涉及复杂的网格拓扑解析，工程量巨大且极易出错。
2. **分布外泛化 (OOD Generalization) 衰减：** 如果真实的物理工况或参数远远超出了第一阶段训练时设定的 DOE 范围，AI 模型的预测精度会断崖式下降。
3. **逆向问题的不适定性 (Ill-posedness)：** **仅用 3 个测点反推多个全局物理参数，可能会陷入局部最优解**（即存在多组不同的参数都能让这 3 个点数值对上）。需要在损失函数中加入严格的物理正则化惩罚项。

开发计划与实施周期

- **Milestone 1 (第 1-4 周)：数据流水线搭建与基线确立**
  - 确定基准零件及分析工况，编写自动化脚本（Python + APDL/Abaqus Python）。
  - **交付标准：**产出 5000-10000 组有限元仿真数据集，并完成图数据（PyG 格式）转换。
- **Milestone 2 (第 5-8 周)：AI 代理模型研发与调优 (阶段一闭环)**
  - 搭建 MeshGraphNet 架构，进行模型训练、超参搜索与测试。
  - **交付标准：**交付达到精度与速度指标的前向推理模型。

- **Milestone 3 (第 9-12 周)：逆向反演与重构算法开发 (阶段二闭环)**
  - 开发基稀疏点全场重构模块。
  - 完成参数校准算法验证和测试。
- **Milestone 4 (第 13-16 周)：系统集成与虚实联调**
  - 将算法封装为便于调用的 API 接口。
  - 引入甲方的真实传感器数据，进行实体验证、边界测试与最终报告交付。

参考文献

1. LEARNING MESH-BASED SIMULATION WITH GRAPH NETWORKS